Fontes de Dados para o Projeto ETL de Videojogos

Integração de Sistemas de Informação — Pentaho Data Integration (Kettle)

1. Objetivo deste documento

Este documento identifica e compara um conjunto reduzido de fontes de dados gratuitas e públicas para o desenvolvimento de um processo ETL relacionado com videojogos. A intenção é manter o projeto simples, mas com diversidade suficiente para demonstrar extração, transformação, integração e persistência de dados utilizando o Pentaho Data Integration (Kettle).

A proposta privilegia fontes que possam ser usadas num contexto académico sem custos e que disponibilizem dados suficientemente ricos para operações como limpeza, normalização, joins, lookups, agregações, filtros e exportação para uma base de dados.

2. Requisitos relevantes do trabalho

De acordo com o enunciado do trabalho, o processo deverá demonstrar as três fases de ETL e deverá trabalhar com diferentes origens e formatos de dados. São especialmente relevantes para este tema:

- Importação ou consumo de dados em pelo menos 2 ou 3 formatos distintos, como CSV, JSON ou XML.
- Utilização de fontes heterogéneas, incluindo ficheiros e APIs REST.
- Limpeza, validação, remoção de duplicados e normalização de dados.
- Aplicação de joins, lookups, merges, agrupamentos, cálculos, ordenação e filtragem.
- Persistência dos resultados numa base de dados e/ou exportação para CSV, JSON ou XML.
- Criação de Jobs no Pentaho para orquestrar as várias transformações e registar o processo.

3. Fontes analisadas

3.1 RAWG Video Games Database API — fonte principal recomendada

A RAWG disponibiliza uma API REST dedicada a videojogos. É a fonte mais adequada para obter os metadados principais de cada jogo e será usada como base central para enriquecer os restantes dados.

Tipo de fonte	API REST
Formato	JSON
Custo	Plano gratuito para projetos pessoais/hobby; adequado ao contexto académico.
Autenticação	É necessária uma API key gratuita.
Limite indicado	Até 20 000 pedidos por mês no plano gratuito.
Dados relevantes	Nome do jogo, data de lançamento, plataformas, géneros, developers, publishers, classificações,

	Metacritic, tempo médio de jogo, ESRB, lojas e outros metadados.
Utilização proposta	Criar a tabela principal de jogos e tabelas auxiliares de géneros, plataformas, developers e publishers.
Limitações	Exige registo e API key. A RAWG exige atribuição da fonte nas utilizações do plano gratuito. Alguns campos podem não estar disponíveis para todos os jogos.

Documentação: https://rawg.io/apidocs

Documentação OpenAPI: https://api.rawg.io/docs/

Exemplo de utilização no projeto: obter uma lista de jogos lançados num determinado período, extrair os campos relevantes do JSON e convertê-los para uma estrutura tabular antes de carregar os dados na base de dados de destino.

3.2 Video Game Sales (vgsales.csv) — fonte principal recomendada

Este dataset histórico contém informação de vendas de videojogos por região. É útil porque introduz uma segunda origem e um segundo formato de dados, além de fornecer métricas que não são o foco principal da RAWG.

Tipo de fonte	Ficheiro público
Formato	CSV
Dimensão	A versão amplamente distribuída contém cerca de 16 598 registos e 11 colunas.
Custo	Gratuito.
Autenticação	Não é necessária para o ficheiro disponibilizado publicamente.
Dados relevantes	Nome, plataforma, ano, género, publisher e vendas na América do Norte, Europa, Japão, outras regiões e vendas globais.
Utilização proposta	Adicionar ao modelo centralizado os dados históricos de vendas e permitir análises por região, plataforma, género, ano e publisher.
Limitações	É um dataset histórico e não deve ser tratado como uma fonte atual de vendas. Existem valores em falta e a correspondência de nomes com outras fontes pode exigir normalização.

Registo/Ficheiro de referência: https://zenodo.org/records/5898311/files/vgsales.csv

Espelho público com descrição do dataset: https://github.com/Abhishekgupta2883/Video-Games-Sales-from-Zenodo-

Esta fonte é particularmente útil para demonstrar problemas reais de integração: o mesmo jogo pode existir em mais de uma plataforma, os nomes podem não coincidir exatamente com os da API e existem valores nulos que terão de ser tratados.

3.3 Steam User Reviews API — fonte opcional

A Steam disponibiliza um endpoint público para obter avaliações de utilizadores de uma aplicação. Esta fonte não é necessária para o núcleo do projeto, mas pode ser usada caso seja pretendido acrescentar uma terceira origem com informação de receção dos jogadores.

Tipo de fonte	API HTTP da Steam
Formato	JSON
Custo	Gratuito.
Autenticação	O endpoint de reviews documentado pode ser consultado através do AppID do jogo.
Dados relevantes	Total de reviews positivas e negativas, score, idioma, texto da review, tempo de jogo, data e outros indicadores.
Utilização proposta	Enriquecer apenas uma seleção de jogos presentes na Steam com dados agregados de reviews.
Limitações	Abrange apenas jogos presentes na Steam e aumenta a complexidade do projeto. Não acrescenta um novo formato, pois também devolve JSON.

Documentação oficial: https://partner.steamgames.com/doc/store/getreviews

Recomendação: manter esta fonte como extensão. O projeto já consegue cumprir a componente principal de integração com RAWG + CSV; a Steam deve ser adicionada apenas se houver tempo e se for útil para enriquecer a análise.

4. Seleção recomendada para o projeto

Fonte	Papel	Formato	Prioridade	Motivo
RAWG API	Metadados atuais dos jogos	JSON	Principal	Fonte rica, estruturada e simples de consultar.
vgsales.csv	Vendas históricas por região	CSV	Principal	Acrescenta métricas diferentes e permite joins e limpeza.
Steam Reviews	Receção dos utilizadores	JSON	Opcional	Interessante, mas aumenta o volume e a complexidade.

Para manter o projeto simples, a proposta inicial é trabalhar apenas com as duas primeiras fontes. A terceira fica documentada como possibilidade de evolução.

5. Como cumprir a diversidade de formatos sem complicar o projeto

As duas fontes principais fornecem JSON e CSV. Caso seja necessário demonstrar um terceiro formato de entrada, é preferível criar um pequeno ficheiro XML auxiliar em vez de adicionar outra API externa.

Esse XML pode conter regras de normalização ou correspondências de plataformas, por exemplo:

- PS4 → PlayStation 4
- PS5 → PlayStation 5
- X360 → Xbox 360
- XB → Xbox
- PC → PC

Desta forma, o projeto passa a consumir JSON + CSV + XML, mas continua com apenas duas fontes externas principais. O ficheiro XML também tem uma função real no processo: normalizar os nomes das plataformas antes do cruzamento dos dados.

6. Dados a recolher de cada fonte

6.1 RAWG

- ID da RAWG
- Nome do jogo
- Data de lançamento
- Plataformas
- Géneros
- Developer(s)
- Publisher(s)
- Rating da RAWG
- Metacritic, quando disponível
- Tempo médio de jogo, quando disponível
- Classificação etária, quando disponível

6.2 vgsales.csv

- Nome do jogo
- Plataforma
- Ano
- Género
- Publisher
- Vendas na América do Norte
- Vendas na Europa
- Vendas no Japão
- Vendas noutras regiões
- Vendas globais

6.3 Steam Reviews (opcional)

- Steam AppID
- Número total de reviews
- Reviews positivas
- Reviews negativas
- Pontuação/descrição da avaliação
- Tempo de jogo dos autores, caso se pretenda análise adicional
- Idioma das reviews, caso seja relevante

7. Transformações que fazem sentido no Pentaho

O interesse do trabalho não estará apenas nos cálculos finais, mas sobretudo na integração de fontes com estruturas diferentes. As seguintes transformações são suficientes para demonstrar os principais operadores do Pentaho:

1. Limpar e normalizar nomes de jogos, removendo espaços duplicados, diferenças de capitalização e caracteres desnecessários.
2. Normalizar os nomes das plataformas através de um lookup num ficheiro XML.
3. Converter datas e anos para tipos consistentes.
4. Identificar e tratar valores nulos em ano, publisher, rating ou Metacritic.
5. Remover duplicados ou decidir como representar o mesmo jogo em diferentes plataformas.
6. Fazer o cruzamento entre RAWG e o CSV por nome normalizado, plataforma e, quando necessário, ano.
7. Calcular vendas totais por género, publisher, plataforma e período.
8. Calcular percentagens das vendas de cada região relativamente às vendas globais.
9. Criar rankings de jogos, plataformas e publishers.
10. Separar registos integrados com sucesso dos registos que não encontraram correspondência, criando um log de qualidade dos dados.

8. Estrutura proposta para os dados centralizados

Não é necessário definir já o modelo final, mas uma estrutura simples poderá conter as seguintes entidades:

- Game — informação principal do jogo.
- Platform — plataformas normalizadas.
- Genre — géneros.
- Publisher — publishers.
- Developer — developers.
- Game_Platform — relação entre jogos e plataformas.
- Sales — vendas históricas por jogo, plataforma e região.
- Rating — ratings provenientes da RAWG e, opcionalmente, da Steam.

Esta estrutura evita guardar tudo numa única tabela e permite demonstrar a criação de relações e lookups durante o ETL.

9. Fluxo ETL proposto

11. Extract RAWG — obter os jogos e respetivos metadados em JSON.
12. Extract CSV — importar o ficheiro histórico de vendas.
13. Extract XML — carregar o pequeno ficheiro de normalização de plataformas.
14. Transform RAWG — selecionar campos, tratar nulos e normalizar texto e datas.
15. Transform Sales — corrigir tipos, limpar valores e normalizar nomes.
16. Lookup Platform — aplicar as correspondências definidas no XML.
17. Match Games — cruzar os dados RAWG e CSV e identificar correspondências e falhas.
18. Aggregate — produzir métricas por género, plataforma, publisher, ano e região.
19. Load — carregar os dados normalizados para SQL.
20. Export — gerar pelo menos um resumo em CSV ou JSON e um log do processo.

10. Análises possíveis

- Jogos e géneros com maiores vendas globais.
- Diferenças de vendas entre Europa, América do Norte e Japão.
- Plataformas com melhores resultados por período.
- Publishers com maior volume de vendas.
- Evolução dos géneros ao longo dos anos.
- Comparação entre classificações da RAWG/Metacritic e vendas históricas, apenas quando existirem correspondências válidas.
- Quantidade e percentagem de registos que puderam ser integrados automaticamente entre as duas fontes.

11. Decisão recomendada

Versão inicial do projeto: RAWG API + vgsales.csv + XML auxiliar de normalização.

Esta combinação é suficientemente simples para um trabalho académico, mas permite demonstrar API REST, JSON, CSV, XML, limpeza de dados, Regex, joins, lookups, agregações, tratamento de erros, persistência SQL e exportação. A Steam Reviews API deve permanecer como melhoria opcional e não como dependência do projeto.

12. Referências e locais relevantes

RAWG API Docs: https://rawg.io/apidocs

RAWG OpenAPI: https://api.rawg.io/docs/

RAWG Terms of Service: https://rawg.io/tos_api

Video Game Sales — ficheiro de referência no Zenodo:
https://zenodo.org/records/5898311/files/vgsales.csv

Espelho e descrição do dataset vgsales.csv: https://github.com/Abhishekgupta2883/Video-Games-Sales-from-Zenodo-

Steam User Reviews — documentação oficial: https://partner.steamgames.com/doc/store/getreviews

Nota: as condições de utilização e os limites das APIs podem ser alterados pelos respetivos fornecedores. Antes da implementação final, deverá ser confirmada novamente a documentação oficial.